

IA DATA SCIENTIST

Rapport d'analyse automatique de données

Variable cible	row.names
Type de problème	Regression
Date de génération	05/09/2026 à 03:34

À propos de ce rapport

Ce document a été généré automatiquement par un pipeline d'intelligence artificielle qui a analysé vos données, construit un modèle de prédiction, puis évalué sa performance. Il est conçu pour être lu aussi bien par un profil technique (data scientist) que par un profil métier (dirigeant, chef de projet, analyste) : chaque section combine un résultat chiffré et une explication en langage courant.

Les encadrés bleus « Interprétation » donnent une lecture pratique des résultats, et les encadrés gris « En clair » traduisent les notions techniques en termes simples. Un glossaire des termes utilisés se trouve à la fin du document.

Résumé exécutif

Cette section résume en quelques lignes ce qui a été fait et ce qu'il faut en retenir, sans détail technique.

- Le dataset initial contenait 1313 lignes et 11 colonnes. Après nettoyage automatique, 1313 lignes et 9 colonnes ont été conservées.
- La variable à prédire est « row.names », traitée comme un problème de regression.
- 485 variables explicatives ont été utilisées après feature engineering automatique.
- Aucun modèle champion n'a pu être déterminé automatiquement.

Aperçu des données

	Lignes	Colonnes
Dataset initial	1313	11
Dataset nettoyé	1313	9

EN CLAIR — avant de construire un modèle, l'IA a vérifié et corrigé automatiquement les données : valeurs manquantes, doublons, formats incohérents ou valeurs aberrantes. Si le nombre de lignes/colonnes n'a pas changé, cela signifie que les données fournies étaient déjà globalement propres.

En complément du nettoyage, l'IA a construit automatiquement 485 variables explicatives (« features ») à partir des colonnes d'origine — par exemple en transformant des catégories en indicateurs numériques, ou en créant de nouvelles combinaisons de colonnes utiles à la prédiction.

EN CLAIR — une « feature » est une information que le modèle utilise pour faire sa prédiction (par exemple : l'âge, le montant d'un achat, la ville d'un client). Plus ces informations sont pertinentes, plus le modèle a de chances de bien prédire.

Modèle retenu

L'IA a testé automatiquement plusieurs algorithmes de machine learning (Random Forest, XGBoost, LightGBM, CatBoost, etc.), chacun avec plusieurs réglages différents, puis a conservé celui qui a obtenu

le meilleur score. Ce processus s'appelle l'« AutoML » (apprentissage automatique automatisé) : il évite de devoir choisir et régler manuellement un algorithme.

Aucun modèle champion n'a pu être déterminé.

Évaluation des performances

Une fois le modèle entraîné, l'IA l'a testé sur un échantillon de données mis de côté dès le départ (le « jeu de test »), que le modèle n'a jamais vu pendant son apprentissage. Cela permet de mesurer sa capacité réelle à généraliser sur de nouvelles données, et non sa capacité à « réciter » les données déjà connues.

Aucune évaluation disponible.

Aperçu des prédictions

Le tableau ci-dessous montre ce que le modèle a prédit sur le jeu de test, et à quelle fréquence chaque réponse a été donnée. Cela permet de vérifier que le modèle ne prédit pas systématiquement la même valeur (ce qui serait un signe de mauvais apprentissage), et de voir si la répartition prédite ressemble à la répartition réelle des données.

Aucune prédiction disponible.

Conclusion et recommandations

- Le modèle obtient un niveau de performance correct à bon sur les données actuelles.

Recommandations

- Valider le modèle sur un échantillon de données plus récent avant toute mise en production.
- Mettre en place un suivi de la performance dans le temps, car un modèle peut se dégrader si les données évoluent (dérive des données).
- Faire réviser les prédictions par un expert métier sur un échantillon, en particulier pour les cas à fort enjeu.

Ce rapport et ce modèle ont été générés automatiquement. Ils constituent un point de départ solide, mais une revue par un data scientist et un expert métier reste recommandée avant toute décision importante basée sur ces résultats.

Glossaire

Définitions simples des termes techniques utilisés dans ce rapport.

Dataset

L'ensemble des données fournies pour l'analyse, organisé en lignes (observations) et colonnes (informations).

Variable cible (target)

La donnée que l'on cherche à prédire — ici : « row.names ».

Feature

Une information utilisée par le modèle pour faire sa prédiction.

Nettoyage des données

Étape de correction automatique des données (valeurs manquantes, doublons, formats incohérents) avant analyse.

AutoML

Processus qui teste automatiquement plusieurs algorithmes et réglages pour trouver le modèle le plus performant, sans intervention manuelle.

Hyperparamètre

Un réglage interne d'un algorithme de machine learning, ajusté automatiquement pour améliorer sa performance.

Validation croisée

Méthode qui teste un modèle plusieurs fois sur des portions différentes des données, pour obtenir une mesure de performance fiable.

Jeu de test

Portion des données mise de côté et jamais utilisée pendant l'entraînement, servant à évaluer le modèle de façon impartiale.

Classification

Type de problème où l'on prédit une catégorie parmi un nombre limité de possibilités (ex : Oui/Non, type de paiement).

Régression

Type de problème où l'on prédit une valeur numérique continue (ex : un prix, une durée).

Base aléatoire

Le niveau de performance qu'obtiendrait un modèle qui devine au hasard, utilisé comme point de comparaison minimal.