

IA DATA SCIENTIST

Rapport d'analyse automatique de données

Variable cible	Sales
Type de problème	Regression
Date de génération	07/09/2026 à 16:44

À propos de ce rapport

Ce document a été généré automatiquement par un pipeline d'intelligence artificielle qui a analysé vos données, construit un modèle de prédiction, puis évalué sa performance. Il est conçu pour être lu aussi bien par un profil technique (data scientist) que par un profil métier (dirigeant, chef de projet, analyste) : chaque section combine un résultat chiffré et une explication en langage courant.

Les encadrés bleus « Interprétation » donnent une lecture pratique des résultats, et les encadrés gris « En clair » traduisent les notions techniques en termes simples. Un glossaire des termes utilisés se trouve à la fin du document.

Résumé exécutif

Cette section résume en quelques lignes ce qui a été fait et ce qu'il faut en retenir, sans détail technique.

- Le dataset initial contenait 200 lignes et 5 colonnes. Après nettoyage automatique, 200 lignes et 5 colonnes ont été conservées.
- La variable à prédire est « Sales », traitée comme un problème de regression.
- 2 variables explicatives ont été utilisées après feature engineering automatique.
- Le modèle retenu (champion) est XGBoost, avec un score de validation croisée de 5.8654.

Aperçu des données

	Lignes	Colonnes
Dataset initial	200	5
Dataset nettoyé	200	5

EN CLAIR — avant de construire un modèle, l'IA a vérifié et corrigé automatiquement les données : valeurs manquantes, doublons, formats incohérents ou valeurs aberrantes. Si le nombre de lignes/colonnes n'a pas changé, cela signifie que les données fournies étaient déjà globalement propres.

En complément du nettoyage, l'IA a construit automatiquement 2 variables explicatives (« features ») à partir des colonnes d'origine — par exemple en transformant des catégories en indicateurs numériques, ou en créant de nouvelles combinaisons de colonnes utiles à la prédiction.

EN CLAIR — une « feature » est une information que le modèle utilise pour faire sa prédiction (par exemple : l'âge, le montant d'un achat, la ville d'un client). Plus ces informations sont pertinentes, plus le modèle a de chances de bien prédire.

Modèle retenu

L'IA a testé automatiquement plusieurs algorithmes de machine learning (Random Forest, XGBoost, LightGBM, CatBoost, etc.), chacun avec plusieurs réglages différents, puis a conservé celui qui a obtenu

le meilleur score. Ce processus s'appelle l'« AutoML » (apprentissage automatique automatisé) : il évite de devoir choisir et régler manuellement un algorithme.

Modèle	XGBoost
Score (validation croisée)	5.8654

EN CLAIR — le « score de validation croisée » mesure la performance du modèle sur des données qu'il n'a jamais vues pendant son entraînement, en la testant plusieurs fois sur des portions différentes du dataset. C'est un indicateur plus fiable qu'un test unique, car il réduit le risque que le score soit dû à la chance.


Hyperparamètres optimisés :

Ce sont les réglages internes de l'algorithme (par exemple : le nombre d'arbres de décision construits, ou la vitesse à laquelle le modèle apprend). L'IA les a testés automatiquement par dizaines de combinaisons pour retenir celle qui fonctionne le mieux sur ces données — vous n'avez rien eu à régler manuellement.

Paramètre	Valeur
n_estimators	350
max_depth	6
learning_rate	0.22711536921581052
subsample	0.9735254341939188
colsample_bytree	0.6558252203355647

Évaluation des performances

Une fois le modèle entraîné, l'IA l'a testé sur un échantillon de données mis de côté dès le départ (le « jeu de test »), que le modèle n'a jamais vu pendant son apprentissage. Cela permet de mesurer sa capacité réelle à généraliser sur de nouvelles données, et non sa capacité à « réciter » les données déjà connues.



Métrique	Valeur
MAE	4.8515
RMSE	6.2660
R2	-0.2439

Que signifient ces métriques ?

MAE	L'écart moyen, en valeur absolue, entre la valeur prédite et la valeur réelle. Plus il est proche de 0, mieux c'est.
RMSE	Similaire au MAE, mais pénalise davantage les grosses erreurs. Utile pour repérer si le modèle se trompe parfois beaucoup.
R2	La part de variation de la valeur cible expliquée par le modèle, de 0 (aucune explication) à 1 (explication parfaite).

INTERPRÉTATION — Le R2 du modèle est de -0.24 : **le modèle explique une faible part de la variation** de la variable cible. Cela suggère que les données actuelles ne contiennent pas assez d'information pour bien prédire cette valeur.

Aperçu des prédictions

Le tableau ci-dessous montre ce que le modèle a prédit sur le jeu de test, et à quelle fréquence chaque réponse a été donnée. Cela permet de vérifier que le modèle ne prédit pas systématiquement la même valeur (ce qui serait un signe de mauvais apprentissage), et de voir si la répartition prédite ressemble à la répartition réelle des données.

Valeur prédite	Occurrences	Part (%)
7.986356	1	2.5%
8.293675	1	2.5%
9.136194	1	2.5%
9.514436	1	2.5%
10.075207	1	2.5%
10.520088	1	2.5%
10.97119	1	2.5%
11.792265	1	2.5%
11.878821	1	2.5%
12.532191	1	2.5%

12.677948	1	2.5%
13.6415615	1	2.5%
14.193149	1	2.5%
14.311664	1	2.5%
14.452933	1	2.5%
14.486112	1	2.5%
15.092057	1	2.5%
15.312172	1	2.5%
15.560807	1	2.5%
15.635242	1	2.5%
15.877846	1	2.5%
16.388645	1	2.5%
17.358257	1	2.5%
17.817587	1	2.5%
18.149088	1	2.5%
18.1744	1	2.5%
18.32853	1	2.5%
18.395641	1	2.5%
18.52564	1	2.5%
18.557348	1	2.5%
18.573679	1	2.5%
19.093164	1	2.5%
20.059084	1	2.5%
20.6281	1	2.5%
20.827662	1	2.5%
21.351765	1	2.5%
22.361053	1	2.5%
23.800507	1	2.5%
23.82534	1	2.5%

24.780622	1	2.5%
-----------	---	------

40 prédictions générées au total sur le jeu de test.

Conclusion et recommandations

- Le modèle XGBoost a été retenu comme meilleur candidat parmi ceux testés automatiquement, avec un score de validation croisée de 5.8654.
- Le niveau de performance actuel reste modeste. Cela ne signifie pas que le projet est un échec : c'est un signal utile qui indique où concentrer les efforts avant une mise en production.

Recommandations

- Vérifier si des informations importantes (données externes, historique client, contexte métier) ne manquent pas dans le dataset actuel.
- Faire relire le choix de la variable cible et sa définition par un expert métier — parfois la question posée au modèle n'est pas la bonne.
- Collecter davantage de données si le volume actuel est limité.
- Explorer manuellement les données avec un data scientist pour identifier de nouvelles variables explicatives pertinentes.
- Augmenter le nombre d'essais d'optimisation (trials) pour permettre à l'AutoML d'explorer davantage de réglages.

Ce rapport et ce modèle ont été générés automatiquement. Ils constituent un point de départ solide, mais une revue par un data scientist et un expert métier reste recommandée avant toute décision importante basée sur ces résultats.

Glossaire

Définitions simples des termes techniques utilisés dans ce rapport.

Dataset

L'ensemble des données fournies pour l'analyse, organisé en lignes (observations) et colonnes (informations).

Variable cible (target)

La donnée que l'on cherche à prédire — ici : « Sales ».

Feature

Une information utilisée par le modèle pour faire sa prédiction.

Nettoyage des données

Étape de correction automatique des données (valeurs manquantes, doublons, formats incohérents) avant analyse.

AutoML

Processus qui teste automatiquement plusieurs algorithmes et réglages pour trouver le modèle le plus performant, sans intervention manuelle.

Hyperparamètre

Un réglage interne d'un algorithme de machine learning, ajusté automatiquement pour améliorer sa performance.

Validation croisée

Méthode qui teste un modèle plusieurs fois sur des portions différentes des données, pour obtenir une mesure de performance fiable.

Jeu de test

Portion des données mise de côté et jamais utilisée pendant l'entraînement, servant à évaluer le modèle de façon impartiale.

Classification

Type de problème où l'on prédit une catégorie parmi un nombre limité de possibilités (ex : Oui/Non, type de paiement).

Régression

Type de problème où l'on prédit une valeur numérique continue (ex : un prix, une durée).

Base aléatoire

Le niveau de performance qu'obtiendrait un modèle qui devine au hasard, utilisé comme point de comparaison minimal.